

**Descripción de los datos para el agrupamiento de patrones de demanda del Metro de
Medellín**

Julian Vega Joya y Alejandro Mora

Ingeniería de Software, Corporación Universitaria Iberoamericana

Inteligencia Artificial (24082026_C1_202634)

Sandra Bautista

[PENDIENTE: fecha de entrega]

Descripción de los datos para el agrupamiento de patrones de demanda del Metro de Medellín

Introducción

Este documento describe los datos del modelo de aprendizaje no supervisado de la Actividad 4. A diferencia de la actividad anterior, aquí no hay una respuesta que predecir: el objetivo es descubrir, sin etiquetas, qué patrones de demanda horaria existen en las estaciones de las líneas A y B del Metro de Medellín. Para eso se usan técnicas de agrupamiento, que reúnen en un mismo grupo los casos parecidos entre sí y separan los distintos (Palma Méndez y Marín Morales, 2008).

El caso que se agrupa es el perfil de una estación en un día: qué parte de los pasajeros de ese día ingresó en cada hora. Dos perfiles se parecen si la demanda se reparte de forma parecida a lo largo del día, sin importar el tamaño de la estación.

Fuentes de datos identificadas

Para esta actividad se revisaron las mismas fuentes públicas de la actividad anterior, porque el agrupamiento también requiere la afluencia por estación y por hora. La Tabla 1 las resume.

Tabla 1

Fuentes de datos identificadas para el proyecto

Fuente	Contenido	Uso en el proyecto	Limitación
Pasajeros movilizados: afluencia (Metro de Medellín, s.f.-a; TUMI, 2023)	Pasajeros por línea, día y hora	Base de los perfiles de demanda	Está agregada por línea, no por estación; el enlace de datos.gov.co respondió "no encontrado" el día de la consulta
Pasajeros movilizados mensual (Metro de Medellín, s.f.-b)	Total de pasajeros por mes	Tendencia y estacionalidad	Demasiado agregada para perfiles horarios

Fuente	Contenido	Uso en el proyecto	Limitación
Estaciones y líneas del sistema (Metro de Medellín, s.f.-c; Alcaldía de Medellín, 2021)	Ubicación georreferenciada de estaciones, línea y modo	Catálogo de estaciones	No contiene demanda
GTFS del Metro de Medellín (ColombiaInfo, s.f.)	Rutas, paradas y horarios en formato GTFS	Orden de estaciones y horario de operación	Sus autores advierten errores en los tiempos
Informe del Metro a ALAMYS (Metro de Medellín, 2017)	Afluencia de 2016 y horas de mayor carga	Calibrar el orden de magnitud de la demanda (cerca de 713 000 usos diarios en las líneas A y B)	Dato puntual de 2016
Calendario de festivos (Ley 51 de 1983)	Días festivos de Colombia	Variable <code>tipo_dia</code>	Ninguna relevante
Red de pluviómetros del SIATA (Sistema de Alerta Temprana de Medellín y el Valle de Aburrá [SIATA], s.f.)	Precipitación por hora	Contexto climático	Fuente candidata; no se descargó

Nota. Elaboración propia con base en las fuentes citadas.

Ninguna fuente pública contiene la afluencia por estación y por hora. Por eso se reutilizó el dataset de muestra construido en la actividad anterior, tal como lo permite el enunciado: "en caso de no existir dichas fuentes de datos, desarrolle un dataset con una muestra de dichos datos".

Datos de partida: afluencia horaria por estación

El archivo `data/afluencia_metro_medellin.csv` tiene 29 176 registros, uno por estación, hora y día, entre el 2 de marzo y el 26 de abril de 2026. Lo genera el script `data/generar_dataset.py` con semilla fija. La Tabla 2 separa lo real de lo simulado.

Tabla 2*Componentes reales y simulados del dataset de afluencia*

Real	Simulado
Nombres, orden y línea de las 27 estaciones (21 en la línea A y 7 en la B; San Antonio pertenece a ambas)	Número de pasajeros por hora
Calendario del 2 de marzo al 26 de abril de 2026, con sus tres festivos	Clima de cada hora y fechas de partidos en el estadio
Horario aproximado de operación: 4:00 a 22:59 de lunes a sábado y 5:00 a 21:59 los domingos y festivos	Tipo de zona y peso de demanda de cada estación (clasificación propia del equipo)
Orden de magnitud de la demanda: cerca de 713 000 usos en un día laboral (Metro de Medellín, 2017)	Perfil horario de cada tipo de zona

La demanda se simuló con perfiles horarios distintos según el tipo de zona: las zonas residenciales concentran sus ingresos en la mañana y las zonas de empleo en la tarde, mientras que los sábados, domingos y festivos no tienen picos marcados. A eso se suman el efecto de la lluvia, el de los partidos en el estadio y un ruido aleatorio. El detalle completo está en la documentación de la actividad anterior.

Datos para el agrupamiento: perfiles estación-día

El script `src/agrupamiento.py` transforma la afluencia en el archivo `data/perfiles_estacion_dia.csv`. Para cada estación y cada día suma los pasajeros de cada hora y los divide entre el total del día. El resultado son 1568 perfiles (28 combinaciones de estación y línea por 56 días), cada uno con 19 fracciones que suman 1.

Se usan fracciones, y no pasajeros, para que el algoritmo compare la forma de la demanda y no su tamaño. Sin esta normalización, San Antonio quedaría sola en un grupo por ser la estación más grande, aunque su patrón horario sea igual al de otras estaciones del centro. La Tabla 3 describe las columnas.

Tabla 3*Diccionario de datos del archivo de perfiles*

Columna	Tipo	Descripción	Uso en el agrupamiento
fecha	Fecha	Día del perfil (2026-03-02 a 2026-04-26)	Identificación
linea, estacion	Categórica	Línea y estación	Identificación
dia_semana	Categórica	Lunes a domingo	Solo para interpretar los grupos
tipo_dia	Categórica	Laboral, Sábado o Domingo_Festivo	Solo para interpretar los grupos
tipo_zona	Categórica	Residencial, Centro_Empleo o Mixta	Solo para interpretar los grupos
hubo_evento	Binaria	1 si hubo partido en el estadio ese día cerca de la estación	Solo para interpretar los grupos
pasajeros_dia	Entera	Total de ingresos del día (5917 a 68 793)	Solo para describir los grupos
h04 a h22	Decimal	Fracción de los ingresos del día que entró en cada hora, de 4:00 a 22:00	Variables del agrupamiento

El algoritmo solo recibe las 19 columnas h04 a h22. El tipo de día, el tipo de zona y el evento se guardan para comprobar después si los grupos que encontró tienen sentido; si se los entregáramos, el agrupamiento perdería su carácter no supervisado.

Resumen estadístico

La Tabla 4 muestra cuántos perfiles hay de cada tipo de día y de zona. Esta distribución no se le entrega al algoritmo; sirve para interpretar sus resultados.

Tabla 4*Distribución de los perfiles por tipo de día y tipo de zona*

Tipo de día	Residencial	Centro y empleo	Mixta	Total
Laboral	444	370	222	1036
Sábado	96	80	48	224
Domingo o festivo	132	110	66	308
Total	672	560	336	1568

De los 1568 perfiles, 30 corresponden a días con partido en las estaciones Estadio o Suramericana. Los domingos y festivos no tienen ingresos a las 4:00 ni a las 22:00, porque el sistema opera de 5:00 a 21:59 esos días.

En cuanto a calidad, cada perfil suma 1, no hay valores nulos ni perfiles duplicados, y el total de pasajeros coincide con el del archivo de afluencia. Esto lo verifican las pruebas D1 a D6 descritas en el documento de pruebas.

Limitaciones

- Los datos son simulados. Los grupos encontrados demuestran que el método funciona, pero no describen la operación real del Metro.
- Como los perfiles se simularon a partir de tipos de zona y de día, es esperable que el algoritmo los recupere. Con datos reales los grupos serían menos nítidos y podrían aparecer patrones nuevos.
- Ocho semanas no permiten observar la estacionalidad anual.
- Solo se cubren las líneas A y B del metro.

Referencias

- Alcaldía de Medellín. (2021). *Estaciones del Sistema de Transporte Masivo* [Conjunto de datos]. GeoMedellín. <https://medellin.gov.co/giscatalogacion/srv/api/records/8dd3580b-d615-4981-9a1f-3ed357c74eee>
- ColombiaInfo. (s.f.). *ColombiaGTFS: Medellín - Metro* [Conjunto de datos]. GitHub. <https://github.com/ColombiaInfo/ColombiaGTFS/tree/master/Medellin%20-%20Metro>
- Ley 51 de 1983. Por la cual se traslada el descanso remunerado de algunos días festivos. (1983). Congreso de la República de Colombia.
- Metro de Medellín. (s.f.-a). *Pasajeros movilizados: afluencia* [Conjunto de datos]. Datos Abiertos Colombia. <https://www.datos.gov.co/Transporte/Pasajeros-Movilizados-Afluencia/9dbb-kbnv>
- Metro de Medellín. (s.f.-b). *Pasajeros movilizados mensual Metro de Medellín* [Conjunto de datos]. MEData. <http://medata.gov.co/dataset/pasajeros-movilizados-mensual-metro-de-medell%C3%ADn>
- Metro de Medellín. (s.f.-c). *Portal de datos abiertos del Metro de Medellín*. <https://datosabiertos-metrodemedellin.opendata.arcgis.com/>
- Metro de Medellín. (2017). *Metro de Medellín* [Informe]. Asociación Latinoamericana de Metros y Subterráneos. <https://alamys.org/wp-content/uploads/2021/04/Metro-de-Medellin.pdf>
- Palma Méndez, J. T., y Marín Morales, R. L. (Coords.). (2008). *Inteligencia artificial: Métodos, técnicas y aplicaciones*. McGraw-Hill.
- Sistema de Alerta Temprana de Medellín y el Valle de Aburrá. (s.f.). *SIATA*. <https://siata.gov.co/>
- TUMI. (2023). *Passengers moved - influence* [Conjunto de datos]. TUMI Data Hub. https://hub.tumidata.org/dataset/passengers_moved_influence_medelln