

**Descripción de los datos para el modelo de predicción de congestión del Metro de
Medellín**

Julian Vega Joya y Alejandro Mora

Ingeniería de Software, Corporación Universitaria Iberoamericana

Inteligencia Artificial (24082026_C1_202634)

Sandra Bautista

9 de octubre de 2026

Descripción de los datos para el modelo de predicción de congestión del Metro de Medellín

Introducción

Este documento describe los datos que alimentan el modelo de aprendizaje supervisado de la Actividad 3. El modelo es un árbol de decisión que predice, para cada estación de las líneas A y B del Metro de Medellín y para cada hora, el nivel de congestión: Bajo, Medio o Alto. Se trata de un problema de clasificación supervisada, porque el algoritmo aprende a partir de ejemplos en los que la respuesta ya se conoce (Palma Méndez y Marín Morales, 2008).

Para que el árbol aprenda se necesitan registros históricos con dos partes: las condiciones de cada hora (estación, día, hora, clima, eventos) y lo que ocurrió en ella (cuántas personas ingresaron). A continuación se presentan las fuentes que se identificaron, el dataset que se construyó y el diccionario de cada archivo.

Fuentes de datos identificadas

Se buscaron fuentes públicas que sirvieran para entrenar el modelo. La consulta se hizo el 7 de octubre de 2026 y sus resultados se resumen en la Tabla 1.

Tabla 1

Fuentes de datos identificadas para el proyecto

Fuente	Contenido	Uso en el proyecto	Limitación
Pasajeros movilizados: afluencia (Metro de Medellín, s.f.-a; TUMI, 2023)	Pasajeros por línea, día y hora	Variable objetivo	Está agregada por línea, no por estación; el enlace de datos.gov.co respondió "no encontrado" el día de la consulta
Pasajeros movilizados mensual (Metro de Medellín, s.f.-b)	Total de pasajeros por mes	Tendencia y estacionalidad	Demasiado agregada para un modelo por hora

Fuente	Contenido	Uso en el proyecto	Limitación
Estaciones y líneas del sistema (Metro de Medellín, s.f.-c; Alcaldía de Medellín, 2021)	Ubicación georreferenciada de estaciones, línea y modo	Catálogo de estaciones y transferencias	No contiene demanda
GTFS del Metro de Medellín (ColombiaInfo, s.f.)	Rutas, paradas y horarios en formato GTFS	Orden de estaciones y frecuencias	Sus autores advierten errores en los tiempos de <code>frecuencias.txt</code> y <code>stop_times.txt</code>
Informe del Metro a ALAMYS (Metro de Medellín, 2017)	Afluencia de 2016 y horas de mayor carga	Calibrar el orden de magnitud de la muestra (cerca de 713 000 usos diarios en las líneas A y B)	Dato puntual de 2016
Calendario de festivos (Ley 51 de 1983)	Días festivos de Colombia	Variable <code>tipo_dia</code>	Ninguna relevante
Red de pluviómetros del SIATA (Sistema de Alerta Temprana de Medellín y el Valle de Aburrá [SIATA], s.f.)	Precipitación por hora	Variable <code>clima</code>	Fuente candidata; no se descargó en esta entrega

Nota. Elaboración propia con base en las fuentes citadas.

Conclusión de la búsqueda

Ninguna fuente pública contiene la afluencia por estación y por hora, que es el nivel de detalle que necesita el modelo. La fuente más cercana publica los pasajeros por línea (Metro de Medellín, s.f.-a). Por esa razón se aplicó la segunda opción del enunciado de la actividad: construir un dataset con una muestra de los datos.

Construcción del dataset de muestra

El script `data/generar_dataset.py` genera una muestra simulada con la estructura que tendría el dato real si el Metro lo publicara por estación. Usa una semilla fija, de modo que cualquier persona que lo ejecute obtiene el mismo archivo. La Tabla 2 separa lo que proviene de la realidad de lo que es simulado.

Tabla 2*Componentes reales y simulados del dataset*

Real	Simulado
Nombres, orden y línea de las 27 estaciones (21 en la línea A y 7 en la B; San Antonio pertenece a ambas)	Número de pasajeros por hora
Estaciones de transferencia con otras líneas o con cable (San Antonio, Acevedo y San Javier)	Clima de cada hora
Calendario del 2 de marzo al 26 de abril de 2026, con sus tres festivos	Fechas de partidos en el estadio
Horario aproximado de operación: 4:00 a 22:59 de lunes a sábado y 5:00 a 21:59 los domingos y festivos	Tipo de zona, peso de demanda y capacidad de referencia de cada estación (clasificación propia del equipo)
Orden de magnitud de la demanda: cerca de 713 000 usos en un día laboral (Metro de Medellín, 2017)	Nivel de congestión resultante

Simulación de la demanda

Para cada estación y hora se calcula un índice de ocupación como el producto de seis factores:

1. El peso de la estación: San Antonio, por ejemplo, tiene más demanda relativa que Madera.
2. El perfil horario según el tipo de zona: las zonas residenciales se cargan en la mañana, cuando las personas salen a trabajar, y las zonas de empleo en la tarde, cuando regresan. Los sábados, domingos y festivos no tienen picos marcados.
3. Un ajuste por día de la semana: 6 % más los viernes y 3 % más los lunes.
4. La lluvia, que aumenta la demanda en 12 %, bajo el supuesto de que con lluvia más personas prefieren el metro.
5. Los eventos masivos, que multiplican la demanda por 1,9 en las estaciones Estadio y Suramericana entre las 17:00 y las 21:59 de los días de partido.
6. Un ruido aleatorio log-normal con $\sigma = 0,15$, porque dos lunes a la misma hora nunca son idénticos.

Después se calcula el número de pasajeros como el índice multiplicado por la capacidad de referencia de la estación.

Asignación de la etiqueta

La etiqueta se obtiene del índice de ocupación con los umbrales de la Tabla 3.

Tabla 3

Umbrales del índice de ocupación para asignar el nivel de congestión

Índice de ocupación	Nivel de congestión
Menor que 0,45	Bajo
Desde 0,45 y menor que 0,80	Medio
0,80 o más	Alto

Diccionario de datos

Archivo *afluencia_metro_medellin.csv*

El archivo tiene 29 176 filas y 13 columnas, con codificación UTF-8 y coma como separador. Cada fila corresponde a una estación en una hora de un día. La Tabla 4 describe cada columna.

Tabla 4

Diccionario de datos del archivo de afluencia

Columna	Tipo	Valores	Descripción	Uso en el modelo
fecha	Fecha	2026-03-02 a 2026-04-26	Día del registro	No se usa; se representa con <i>dia_semana</i> y <i>tipo_dia</i>
<i>dia_semana</i>	Categórica	Lunes a domingo	Día de la semana	Predictora
<i>tipo_dia</i>	Categórica	Laboral, Sábado, Domingo_Festivo	Los festivos operan como domingo	Predictora
hora	Entera	4 a 22	Hora de inicio del intervalo (18 equivale a 18:00–18:59)	Predictora
linea	Categórica	A, B	Línea del metro	Predictora
estacion	Categórica	27 estaciones	Nombre de la estación	Predictora

Columna	Tipo	Valores	Descripción	Uso en el modelo
tipo_zona	Categórica	Residencial, Centro_Empleo, Mixta	Uso predominante del entorno	Predictora
es_transferencia	Binaria	0, 1	1 si conecta con otra línea férrea o de cable	Predictora
clima	Categórica	Seco, Lluvia	Condición en esa hora	Predictora
evento_especial	Binaria	0, 1	1 si hay un evento masivo cerca en esa hora	Predictora
pasajeros_hora	Entera	83 a 10 822	Ingresos a la estación en la hora	Excluida, porque de ella se deriva la etiqueta
indice_ocupacion	Decimal	0,043 a 3,491	Pasajeros divididos entre la capacidad de referencia	Excluida, porque de ella se deriva la etiqueta
nivel_congestion	Categórica	Bajo, Medio, Alto	Etiqueta que se quiere predecir	Variable objetivo

Las columnas pasajeros_hora e indice_ocupacion se conservan en el archivo porque son la medición, pero se excluyen del entrenamiento. Si el árbol las recibiera, le bastaría aprender los dos umbrales de la Tabla 3 para acertar siempre, sin haber aprendido nada útil. Además, en la práctica no se conocen antes de que ocurra la hora que se quiere predecir. Este problema se conoce como fuga de información.

Archivo estaciones.csv

El catálogo tiene 28 filas porque San Antonio aparece una vez por cada línea. Sus columnas se describen en la Tabla 5.

Tabla 5*Diccionario de datos del catálogo de estaciones*

Columna	Descripción
estacion, linea	Identifican la estación
orden_en_linea	Posición dentro de la línea (1 corresponde a Niquía en la línea A y a San Antonio en la B)
tipo_zona	Residencial, Centro_Empleo o Mixta
es_transferencia	1 para San Antonio, Acevedo y San Javier
peso_demanda	Demanda relativa de la estación frente a su capacidad (simulado)
capacidad_referencia_hora	Pasajeros por hora que la estación atiende sin aglomeración (simulado)

Resumen estadístico

La Tabla 6 muestra cómo se distribuye la etiqueta. Las clases están desbalanceadas, con pocos casos Alto, como ocurre en la realidad: la congestión alta se concentra en pocas horas del día. Por eso la división entre entrenamiento y prueba se hace de forma estratificada y, además de la exactitud, se reporta el F1 por clase.

Tabla 6*Distribución del nivel de congestión*

Nivel	Registros	Porcentaje
Bajo	13 702	47,0 %
Medio	11 008	37,7 %
Alto	4 466	15,3 %
Total	29 176	100,0 %

La Tabla 7 resume las demás variables.

Tabla 7*Distribución de las variables de contexto*

Variable	Distribución
tipo_dia	Laboral: 19 684 registros (37 días); Domingo_Festivo: 5236 (11 días); Sábado: 4256 (8 días)
clima	Seco: 22 344 (76,6 %); Lluvia: 6832 (23,4 %)
evento_especial	Sin evento: 29 026; con evento: 150 (0,5 %)
pasajeros_hora	Media: 1232; mediana: 1025; máximo: 10 822

En cuanto a calidad, el archivo no tiene valores nulos ni registros duplicados, y todas las categorías están dentro de los valores esperados. Esto lo verifican las pruebas D1 a D9 descritas en el documento de pruebas.

Limitaciones

- Los datos son simulados. Los resultados demuestran que el flujo y el método funcionan, pero no describen la operación real del Metro.
- El modelo aprende, en parte, las mismas reglas con las que se generaron los datos. Con datos reales la exactitud sería distinta y habría que evaluarla de nuevo.
- Solo se cubren las líneas A y B del metro; no se incluyen cables, tranvía ni buses.
- Ocho semanas no alcanzan para capturar la estacionalidad anual, como las vacaciones o diciembre.
- El paso siguiente sería solicitar al Metro la afluencia por estación, obtenida de las validaciones de la tarjeta Cívica, y reemplazar el archivo simulado. El código no tendría que cambiar.

Referencias

- Alcaldía de Medellín. (2021). *Estaciones del Sistema de Transporte Masivo* [Conjunto de datos]. GeoMedellín. <https://medellin.gov.co/giscatalogacion/srv/api/records/8dd3580b-d615-4981-9a1f-3ed357c74eee>
- ColombiaInfo. (s.f.). *ColombiaGTFS: Medellín - Metro* [Conjunto de datos]. GitHub. <https://github.com/ColombiaInfo/ColombiaGTFS/tree/master/Medellin%20-%20Metro>
- Ley 51 de 1983. Por la cual se traslada el descanso remunerado de algunos días festivos. (1983). Congreso de la República de Colombia.
- Metro de Medellín. (s.f.-a). *Pasajeros movilizados: afluencia* [Conjunto de datos]. Datos Abiertos Colombia. <https://www.datos.gov.co/Transporte/Pasajeros-Movilizados-Afluencia/9dbb-kbnv>
- Metro de Medellín. (s.f.-b). *Pasajeros movilizados mensual Metro de Medellín* [Conjunto de datos]. MEData. <http://medata.gov.co/dataset/pasajeros-movilizados-mensual-metro-de-medell%C3%ADn>
- Metro de Medellín. (s.f.-c). *Portal de datos abiertos del Metro de Medellín*. <https://datosabiertos-metrodemedellin.opendata.arcgis.com/>
- Metro de Medellín. (2017). *Metro de Medellín* [Informe]. Asociación Latinoamericana de Metros y Subterráneos. <https://alamys.org/wp-content/uploads/2021/04/Metro-de-Medellin.pdf>
- Palma Méndez, J. T., y Marín Morales, R. L. (Coords.). (2008). *Inteligencia artificial: Métodos, técnicas y aplicaciones*. McGraw-Hill.
- Sistema de Alerta Temprana de Medellín y el Valle de Aburrá. (s.f.). *SIATA*. <https://siata.gov.co/>
- TUMI. (2023). *Passengers moved - influence* [Conjunto de datos]. TUMI Data Hub. https://hub.tumidata.org/dataset/passengers_moved_influence_medelln