

**Predicción del nivel de congestión en las estaciones del Metro de Medellín con árboles de
decisión**

Julian Vega Joya y Alejandro Mora

Ingeniería de Software, Corporación Universitaria Iberoamericana

Inteligencia Artificial

[PENDIENTE: nombre del docente]

8 de octubre de 2026

Predicción del nivel de congestión en las estaciones del Metro de Medellín con árboles de decisión

Presentación

Este documento reúne los enlaces de la Actividad 5 del curso, dedicada a los métodos de aprendizaje supervisado. El proyecto continúa el trabajo sobre el sistema de transporte masivo de las actividades anteriores: construye un árbol de decisión que predice si una estación de las líneas A y B del Metro de Medellín tendrá congestión baja, media o alta en una hora determinada, a partir de la estación, la hora, el día, el clima y la presencia de eventos masivos.

Enlaces de la entrega

La Tabla 1 presenta los enlaces al repositorio y al video. El docente fue agregado como colaborador del repositorio para que pueda revisar el código y dejar comentarios.

Tabla 1

Enlaces de la entrega

Elemento	Enlace
Repositorio Git	[PENDIENTE: enlace del repositorio]
Video explicativo (máximo 10 minutos)	[PENDIENTE: enlace del video]

Elementos alojados en el repositorio

Los cinco elementos solicitados se encuentran en el repositorio, como lo muestra la Tabla 2.

Tabla 2

Ubicación de los entregables en el repositorio

N.º	Entregable	Ubicación	Contenido
1	Archivos de fuentes de datos	data/afluencia_metro_medellin.csv, data/estaciones.csv, data/generar_dataset.py	Dataset de muestra con 29 176 registros horarios por estación, catálogo de estaciones y script que lo genera

N.º	Entregable	Ubicación	Contenido
2	Código fuente en Python	src/modelo_congestion.py, src/predecir.py	Entrenamiento, evaluación y consulta del árbol de decisión
3	Documento con la descripción de los datos	docs/Descripcion_de_los_datos.pdf	Fuentes identificadas, diccionario de datos, supuestos y limitaciones
4	Documento con las pruebas realizadas	docs/Pruebas_realizadas.pdf, tests	Evaluación del modelo, 27 pruebas automáticas y pruebas manuales
5	Video	[PENDIENTE: enlace del video]	Explicación del proyecto, los comandos y los resultados, con la participación de todos los integrantes

Resumen del proyecto

Como no existe una fuente pública con la afluencia por estación y por hora, se construyó un dataset de muestra simulado, tal como lo permite el punto 2 de la actividad. Las estaciones, el calendario y el orden de magnitud de la demanda son reales; el número de pasajeros es simulado.

El modelo es un árbol de decisión con criterio de entropía, es decir, de ganancia de información (Palma Méndez y Marín Morales, 2008), implementado con scikit-learn (Pedregosa et al., 2011). Sus hiperparámetros se eligieron con validación cruzada de cinco particiones. Los resultados se presentan en la Tabla 3.

Tabla 3

Resultados obtenidos

Métrica	Valor
Registros (entrenamiento / prueba)	29 176 (23 340 / 5836)
Exactitud en el conjunto de prueba	84,0 %
Línea base (predecir siempre la clase más frecuente)	47,0 %
Exactitud en validación cruzada	83,7 %
Exactitud en entrenamiento	85,9 %

Métrica	Valor
F1 macro	0,830
Errores graves (confundir Bajo con Alto)	0 de 5836
Pruebas automáticas aprobadas	27 de 27

Ejecución del proyecto

El proyecto se ejecuta con los siguientes comandos desde la carpeta del repositorio:

```
pip install -r requirements.txt
python src/modelo_congestion.py
python -m pytest tests -v
python src/predecir.py --estacion "San Antonio" --dia Viernes --hora 18
```

Referencias

Palma Méndez, J. T., y Marín Morales, R. L. (Coords.). (2008). *Inteligencia artificial:*

Métodos, técnicas y aplicaciones. McGraw-Hill.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M.,

Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D.,

Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in

Python. *Journal of Machine Learning Research*, 12, 2825–2830.