

Pruebas realizadas al modelo de predicción de congestión del Metro de Medellín

Julian Vega Joya y Alejandro Mora

Ingeniería de Software, Corporación Universitaria Iberoamericana

Inteligencia Artificial (24082026_C1_202634)

Sandra Bautista

9 de octubre de 2026

Pruebas realizadas al modelo de predicción de congestión del Metro de Medellín

Introducción

Este documento presenta las pruebas aplicadas al componente desarrollado en la Actividad 3: el árbol de decisión de `src/modelo_congestion.py` y el dataset que lo alimenta. Las pruebas se ejecutaron el 7 de octubre de 2026 en un entorno con Python 3.13, scikit-learn 1.9, pandas 3.0 y pytest 9.1.

Metodología

Se aplicaron tres tipos de prueba:

1. Evaluación estadística del modelo, para medir qué tan bien clasifica datos que nunca vio.
2. Pruebas automáticas con pytest (27 casos), que revisan la calidad de los datos y el comportamiento del modelo y se pueden repetir en cualquier momento.
3. Pruebas manuales de casos, mediante consultas desde la línea de comandos para comprobar que las respuestas tienen sentido.

Para repetir las pruebas se ejecutan estos comandos desde la carpeta del proyecto:

```
python src/modelo_congestion.py  
python -m pytest tests -v
```

Evaluación estadística del modelo

Protocolo

- Se usaron 29 176 registros, divididos en 80 % para entrenamiento (23 340) y 20 % para prueba (5836). La división fue estratificada por la etiqueta y con semilla fija (42).
- Los hiperparámetros se eligieron solo con los datos de entrenamiento, mediante validación cruzada de cinco particiones. El conjunto de prueba se usó una única vez, al final.
- El árbol usa la entropía como criterio de división, es decir, la ganancia de información en la que se basan los algoritmos ID3 y C4.5 (Palma Méndez y Marín Morales, 2008).

La implementación es la de scikit-learn (Pedregosa et al., 2011).

Búsqueda de hiperparámetros

Se probaron 35 combinaciones: siete profundidades y cinco tamaños mínimos de hoja (Tabla 1).

Tabla 1

Hiperparámetros evaluados con validación cruzada

Hiperparámetro	Valores probados	Valor elegido
max_depth	3, 5, 8, 10, 12, 15 y sin límite	Sin límite
min_samples_leaf	1, 5, 10, 20 y 40	10

El árbol resultante tiene profundidad 31 y 1017 hojas. Es grande porque la estación se codifica en 27 columnas de ceros y unos, y el árbol solo puede preguntar por una estación a la vez. Lo que controla el sobreajuste es el tamaño mínimo de hoja: ninguna regla puede apoyarse en menos de 10 ejemplos, lo que cumple el papel de la poda.

Resultados en el conjunto de prueba

La Tabla 2 resume el desempeño general.

Tabla 2

Desempeño general del modelo

	Métrica	Valor
Exactitud en prueba		84,0 %
Exactitud en validación cruzada		83,7 %
Exactitud en entrenamiento		85,9 %
F1 macro		0,830
Línea base (predecir siempre "Bajo")		47,0 %

El modelo acierta 37 puntos porcentuales más que la línea base, y la diferencia entre entrenamiento y prueba es de 1,9 puntos, lo que indica que generaliza y no memorizó los datos. La Tabla 3 muestra el desempeño por clase.

Tabla 3*Desempeño por nivel de congestión en el conjunto de prueba*

Nivel	Precisión		Exhaustividad (recall)	F1	Casos
Bajo	0,880	0,901		0,890	2741
Medio	0,789	0,787		0,788	2202
Alto	0,841	0,784		0,812	893

La matriz de confusión (Tabla 4 y Figura 1) compara el nivel real con el que predijo el modelo.

Tabla 4*Matriz de confusión del conjunto de prueba*

Nivel real	Predijo Bajo	Predijo Medio	Predijo Alto
Bajo	2470	271	0
Medio	337	1733	132
Alto	0	193	700

Figura 1

Matriz de confusión del conjunto de prueba

		Matriz de confusión (conjunto de prueba)		
Nivel real	Bajo	2.470 90%	271 10%	0 0%
	Medio	337 15%	1.733 79%	132 6%
	Alto	0 0%	193 22%	700 78%
		Bajo	Medio	Alto
		Nivel que predijo el modelo		

Ningún caso Alto se predijo como Bajo, ni al contrario. Los 933 errores ocurren entre niveles vecinos (Bajo y Medio, o Medio y Alto), que son los menos costosos. El punto débil es el nivel Medio, que está en la mitad y se confunde hacia ambos lados.

Techo teórico de exactitud


El modelo no llega al 100 % porque los datos tienen ruido aleatorio a propósito: una hora cuyo índice esperado es 0,79 a veces queda en 0,82 (Alto) y a veces en 0,76 (Medio), y eso no se puede predecir con las variables disponibles. Se calculó la exactitud que tendría alguien que conociera la fórmula exacta con la que se generaron los datos, sin el ruido: 85,4 %. El árbol alcanza 84,0 %, es decir, aprendió casi todo lo que era posible aprender.

Efecto de la profundidad y sobreajuste

La Tabla 5 y la Figura 2 muestran qué pasa al variar solo la profundidad máxima, con un tamaño mínimo de hoja de 1.

Tabla 5*Exactitud según la profundidad máxima del árbol*

Profundidad	Entrenamiento	Validación cruzada
2	55,2 %	55,2 %
4	62,4 %	62,4 %
6	70,5 %	70,3 %
8	77,6 %	77,0 %
10	80,2 %	78,8 %
12	82,5 %	80,0 %
14	84,8 %	80,9 %
16	86,6 %	81,5 %
20	88,5 %	81,1 %
25	89,6 %	80,5 %

Figura 2*Exactitud en entrenamiento y en validación cruzada según la profundidad*

A partir de la profundidad 16 la exactitud de entrenamiento sigue subiendo, pero la de validación baja: el árbol empieza a memorizar el ruido. Este es el sobreajuste que justifica la poda de los árboles de decisión (Palma Méndez y Marín Morales, 2008). Con un tamaño mínimo de hoja de 10, la validación sube a 83,7 %, por encima de cualquier punto de la curva.

Estructura del árbol e importancia de las variables


La Figura 3 muestra los dos primeros niveles del árbol. La primera pregunta es si la hora es anterior a las 20:00. En las horas del día, la siguiente pregunta es si se trata de un domingo o festivo; en la noche, el tipo de zona.

Figura 3

Primeros dos niveles del árbol de decisión

Primeros 2 niveles del árbol de decisión


value = proporción de cada clase en el nodo, en el orden [Alto, Bajo, Medio]



La Tabla 6 y la Figura 4 muestran cuánto aporta cada variable a las decisiones del árbol.

Tabla 6*Importancia de las variables en el árbol*

Variable	Importancia
hora	40,4 %
estacion	22,9 %
tipo_dia	13,4 %
tipo_zona	11,1 %
es_transferencia	4,9 %
dia_semana	2,4 %
linea	2,4 %
clima	1,6 %
evento_especial	0,9 %

Figura 4*Importancia de las variables en el árbol*

La hora y la estación explican casi dos tercios de la decisión. La variable `evento_especial` pesa poco en el total porque solo aplica al 0,5 % de los registros, pero donde aplica cambia la predicción, como lo muestran los casos 7 y 8 de la Tabla 9.

Pruebas automáticas

Las 27 pruebas automáticas pasaron, con un tiempo de ejecución de 18 segundos. La Tabla 7 presenta las pruebas de calidad de los datos (`tests/test_datos.py`).

Tabla 7

Pruebas de calidad de los datos

ID	Qué verifica	Resultado
D1	El archivo tiene las 13 columnas esperadas, en orden	Aprobada
D2	No hay valores nulos	Aprobada
D3	No hay registros duplicados (misma fecha, hora, línea y estación)	Aprobada
D4	Las horas están dentro del horario de operación (4 a 22; domingos 5 a 21)	Aprobada
D5	Hay 27 estaciones (21 en la línea A y 7 en la B) y coinciden con el catálogo	Aprobada
D6	Las variables categóricas solo tienen valores válidos	Aprobada
D7	La etiqueta corresponde a los umbrales y el índice es pasajeros entre capacidad	Aprobada
D8	Los tres festivos del periodo están marcados como Domingo_Festivo	Aprobada
D9	El generador es reproducible: al ejecutarlo de nuevo produce el mismo archivo	Aprobada

La Tabla 8 presenta las pruebas del comportamiento del modelo (`tests/test_modelo.py`).

Tabla 8

Pruebas del comportamiento del modelo

ID	Qué verifica	Criterio	Obtenido	Resultado
M1	No hay fuga de información: el modelo no usa <code>pasajeros_hora</code> ni <code>indice_ocupacion</code>	0 columnas prohibidas	0	Aprobada
M2	Exactitud mínima en prueba	80 % o más	84,0 %	Aprobada
M3	Ventaja sobre la línea base	25 puntos o más	37,0 puntos	Aprobada
M4	Sobreajuste controlado (entrenamiento menos prueba)	5 puntos o menos	1,9 puntos	Aprobada

ID	Qué verifica	Criterio	Obtenido	Resultado
M5	Exhaustividad de la clase Alto	70 % o más	78,4 %	Aprobada
M6	Errores graves (confundir Bajo con Alto)	Menos de 1 %	0 %	Aprobada
M7	Dos entrenamientos con los mismos datos dan las mismas predicciones	Idénticas	Idénticas	Aprobada
M8	Casos de sentido común (Tabla 9)	8 de 8	8 de 8	Aprobada
M9	Una estación que no existe en el entrenamiento no rompe el modelo	Clase válida	Clase válida	Aprobada
M10	Las probabilidades están entre 0 y 1 y suman 1	Siempre	Siempre	Aprobada
M11	Un archivo sin las columnas necesarias se rechaza con un error claro	ValueError	ValueError	Aprobada

La Tabla 9 detalla los casos de sentido común de la prueba M8. Los casos 2 y 3, y los casos 7 y 8, son pares: la misma estación a la misma hora, cambiando una sola variable. Sirven para comprobar que el árbol aprendió el efecto del festivo y del evento.

Tabla 9

Casos de sentido común evaluados en la prueba M8

Caso	Estación	Día y hora	Condición	Esperado	Predicho
1	San Antonio (A)	Viernes 18:00	Ninguna	Alto	Alto
2	Niquía	Lunes 6:00	Ninguna	Alto	Alto
3	Niquía	Lunes 6:00	Festivo	Bajo	Bajo
4	La Estrella	Domingo 6:00	Lluvia	Bajo	Bajo
5	Poblado	Martes 22:00	Ninguna	Bajo	Bajo
6	Madera	Martes 7:00	Ninguna	Medio	Medio
7	Estadio	Sábado 19:00	Sin partido	Bajo	Bajo
8	Estadio	Sábado 19:00	Con partido	Alto	Alto

Pruebas manuales

Se hicieron consultas desde la línea de comandos con `src/predecir.py`. Las tres primeras comprueban predicciones normales; las dos últimas, entradas inválidas que el programa rechaza con un mensaje comprensible en lugar de fallar.

```
> python src/predecir.py --estacion "San Antonio" --dia Viernes --hora 18
Nivel de congestión esperado: ALTO

> python src/predecir.py --estacion Suramericana --dia Miércoles --hora 18
Nivel de congestión esperado: MEDIO

> python src/predecir.py --estacion Suramericana --dia Miércoles --hora 18 --evento
Nivel de congestión esperado: ALTO

> python src/predecir.py --estacion Chapinero --dia Martes --hora 7
Estación no encontrada: 'Chapinero'.

> python src/predecir.py --estacion Poblado --dia Martes --hora 3
La hora debe estar entre 4 y 22 (horario de operación).
```

Hallazgo durante las pruebas

En la primera versión del dataset solo había seis fechas de partido, es decir, 60 registros con evento (0,2 % del total). Al probar el caso 8, el modelo respondió Bajo con partido y sin partido: no había aprendido el efecto del evento, y la importancia de esa variable era de 0,1 %. Con tan pocos ejemplos, y con un mínimo de 10 por hoja, el árbol no tenía de dónde sacar esa regla.

El problema se corrigió ampliando la muestra a 15 fechas de partido (150 registros), lo que además es más realista para un estadio con dos equipos locales. Después del cambio el caso 8 se aprueba y la exactitud general se mantuvo (pasó de 83,8 % a 84,0 %). La lección es que una exactitud global alta puede ocultar fallas en los casos poco frecuentes, que a veces son justamente los que más interesa predecir. Por eso los casos 7 y 8 quedaron como prueba automática.

Limitaciones

- Las pruebas miden qué tan bien el árbol recupera patrones de datos simulados. No demuestran que vaya a alcanzar 84 % con datos reales del Metro.
- La división entre entrenamiento y prueba es aleatoria. Con datos reales convendría probar también una división por fechas: entrenar con semanas pasadas y evaluar con semanas posteriores.

- El efecto de la lluvia es pequeño (12 %) y el árbol casi no lo usa (1,6 % de importancia); solo cambia la predicción en casos cercanos a un umbral.
- Con otras versiones de scikit-learn los resultados pueden variar en décimas.

Referencias

- Palma Méndez, J. T., y Marín Morales, R. L. (Coords.). (2008). *Inteligencia artificial: Métodos, técnicas y aplicaciones*. McGraw-Hill.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.